

## 주성분분석(PCA)의 최적 방향

데이터를 한 방향으로 압축할 때, 정보를 가장 많이 남기는 방향은 어떻게 고를까요.

선형대수 · 고유값 · 분해

### PCA의 최적 방향

#### 기본 설명

중심화된 데이터 행렬  $X \in \mathbb{R}^{n \times d}$ 의 공분산행렬을  $\Sigma = \frac{1}{n} X^T X$  라 하자.  $\|w\| = 1$ 인  $w$  중 사영분산  $w^T \Sigma w$ 를 최대화하는 것은  $\Sigma$ 의 최대 고유값에 대응하는 고유벡터이다.

#### 문제

제약이 있는 최댓값 문제이므로 라그랑주 승수법을 쓴다. 라그랑지안은  $L(w, \lambda) = w^T \Sigma w - \lambda(\text{---})$ 로 쓴다. 빈칸을 채우시오.

힌트 보기

정답 보기

## 주성분분석(PCA)의 최적 방향

선형대수 · 고유값 · 분해  
PCA의 최적 방향

해설

괄호 안에는 제약이 지켜졌는지를 0이 되는 식으로 적어요. 우리 제약은  $\|w\| = 1$ 이에요. 이걸  $w^T w - 1 = 0$  형태로 바꿔서 그대로 넣은 거예요. 정답:  $w^T w - 1$

숫자로 먼저 보기

공분산행렬이  $\Sigma = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$  이면 고유값은 4와 2, 고유벡터는  $(1, 1)/\sqrt{2}$ 와  $(1, -1)/\sqrt{2}$ .  $w = (1, 1)/\sqrt{2}$ 에서 사영분산  $w^T \Sigma w = 4$ 로 최댓값을 얻는다.

CALC

## 경사하강법의 하강 보장

학습률이 너무 크면 오히려 손실이 늘어날 수 있어요. 얼마나 작아야 안전할까요.

미적분 · 최적화 · 경사기반 옵티마이저

### 경사하강법의 하강 보장

기본 설명

$\nabla L$ 이 립시츠 상수  $K$ 로 립시츠 연속이면,  $\eta < 1/K$ 일 때  $\theta' = \theta - \eta \nabla L(\theta)$ 는  $L(\theta') \leq L(\theta)$ 를 만족한다.

문제

경사하강법의 갱신식  $\theta' = \theta - \eta \nabla L(\theta)$ 을 2차 상한식에 대입할 차례다. 이항만 하면  $\theta' - \theta = \underline{\hspace{1cm}}$ 이다. 빈칸을 채우시오.

힌트 보기

정답 보기

CALC

## 경사하강법의 하강 보장

미적분 · 최적화

경사기반 옵티마이저

해설

갱신식을 그대로 옮겨 적으면 나오는 식이에요. 별도의 계산이 필요 없어요. 정답:  $-\eta \nabla L(\theta)$

숫자로 먼저 보기

$L(\theta) = \theta^2$ ,  $\theta = 3$ ,  $\eta = 0.2$ 로 한 스텝:  $\theta' = 3 - 0.2 \times 6 = 1.8$ .  $L(3) = 9$ ,  $L(1.8) = 3.24$  — 손실이 5.76만큼 줄었다.

관련 개념

다음 문제

PROB

베이즈 정리

평소에 믿던 확률에 새 증거가 더해지면, 믿음은 정확히 어떻게 바뀔까요.

확률 · 통계 · 분포 · 추정

베이즈 정리

기본 설명

사건  $A, B (P(B) > 0)$ 에 대해  $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$ . 나이브베이즈부터 베이지안 딥러닝까지 확률적 추론의 뿌리.

문제

$P(B|A) = \frac{P(A \cap B)}{P(A)}$ 의 양변에  $P(A)$ 를 곱하면  $P(A \cap B) = \text{----}$ 입니다. 빈칸을 채우시오.

힌트 보기

정답 보기

## PROB

## 베이즈 정리

확률 · 통계  
분포 · 추정

## 해설

조건부확률의 정의를 그대로 이항한 것뿐이에요. **정답:**  $P(B|A)P(A)$  — 이 공통항이 베이즈 정리 양변을 잇는 다리가 됩니다.

## 숫자로 먼저 보기

질병 검사 예시: 유병률 1%, 검사 민감도 99%, 위양성률 5%일 때 양성 판정을 받아도 실제 감염 확률은 약 16.7%에 불과하다 — 사전확률의 영향력을 보여주는 대표 사례.

관련 개념

다음 문제

## INFO

## 교차엔트로피와 엔트로피·KL발산의 관계

분류 모델의 교차엔트로피 손실, 사실은 두 조각으로 쪼개져 있어요.

정보이론 · 엔트로피 · 손실

$$\text{교차엔트로피} = \text{엔트로피} + \text{KL발산}$$

## 기본 설명

두 분포  $p, q$ 에 대해  $H(p, q) = H(p) + D_{KL}(p||q)$ . 교차엔트로피를 줄이는 일이 왜 예측을 정답에 가깝게 만드는지 이 관계로 설명된다.

## 문제

로그의 성질  $\log(p/q) = \log p - \log q$ 를 쓰면  $D_{KL}(p||q) = \sum_x p(x) \log p(x) - \sum_x \text{---}$ 입니다. 빈칸을 채우시오.

힌트 보기

정답 보기

## INFO

## 교차엔트로피와 엔트로피·KL발산의 관계

정보이론  
엔트로피 · 손실

해설

$D_{KL}$ 의 정의  $\sum_x p(x) \log \frac{p(x)}{q(x)}$ 에서 로그의 뺄셈 성질만 적용한 것. **정답:**  $p(x) \log q(x)$

숫자로 먼저 보기

$p = (0.5, 0.5)$ ,  $q = (0.9, 0.1)$ 이면  $H(p) = 1\text{bit}$ ,  $D_{KL}(p||q) \approx 0.74\text{bit}$ 이므로  $H(p, q) \approx 1.74\text{bit}$  — 예측이 부정확할수록 교차엔트로피가 커진다.

관련 개념

다음 문제



DISC

## 의사결정나무 재귀 분기의 정지성

계속 둘로 쪼개며 자라는 나무, 정말 유한 번 만에 멈춘다는 보장이 있을까요.

이산수학 · 트리 · 앙상블 구조

### 재귀 분기의 정지성

#### 기본 설명

유한한  $n$ 개의 데이터로 시작한 의사결정나무에서, 매 분기가 노드의 데이터를 두 개의 비어있지 않은 부분집합으로 나눈다면, 전체 재귀적 분기 과정은 최대  $n - 1$ 번의 분기 안에 멈춘다.

#### 문제

분기가 한 번 일어날 때마다 잎 하나가 사라지고 잎 두 개가 새로 생긴다. 분기를  $k$ 번 반복한 뒤의 잎 개수는 ---- 이다. 빈칸을 채우시오.

힌트 보기

정답 보기

DISC

## 의사결정나무 재귀 분기의 정지성

이산수학

트리 · 앙상블 구조

해설

처음엔 잎이 1개(뿌리)이고, 분기마다 정확히 1개씩 늘어난다. 정답:  $1 + k$

숫자로 먼저 보기

$n = 8$ 개 데이터로 시작해 매번 정확히 반으로 쪼개면 최대 7번 분기(잎 8개)에서 멈춘다  $\rightarrow n - 1 = 7$ 과 정확히 일치.

관련 개념

다음 문제

NUMERIC

## 조건수와 선형시스템의 오차 민감도

아주 작은 반올림 오차가 계산 과정에서 얼마나 크게 부풀려질 수 있을까요.

수치해석 · 수치적 안정성

### 조건수와 오차 민감도

#### 기본 설명

$Ax = b$ 에서  $b$ 에 오차  $\delta b$ 가 생기면, 조건수가 클수록( $A$ 가 ill-conditioned일수록) 해  $x$ 의 오차가 크게 증폭된다.

#### 문제

$A(x + \delta x) = b + \delta b$ 에서 원래 식  $Ax = b$ 를 빼면  $A\delta x = \delta b$ . 양변에  $A^{-1}$ 을 곱하면  $\delta x = \underline{\hspace{2cm}}$ 입니다. 빈칸을 채우시오.

힌트 보기

정답 보기

NUMERIC

## 조건수와 선형시스템의 오차 민감도

수치해석  
수치적 안정성

해설

양변에 역행렬을 곱해  $x$ 의 계수를 지운 것뿐이에요. 정답:  $A^{-1}\delta b$

숫자로 먼저 보기

조건수가 100인 행렬이면, 입력 오차가 0.1%여도 해의 오차는 최대 10%까지 부풀려질 수 있다 — 선형회귀의  $(X^T X)^{-1}$  계산에서 실제로 발생하는 문제.

관련 개념

다음 문제