


주성분분석(PCA)의 최적 방향

데이터를 한 방향으로 압축해서 보고 싶습니다. 그런데 정보를 가장 많이 남기는 방향은 어떻게 고를까요. PCA의 답은 단순해요. 데이터가 가장 넓게 퍼진 방향을 고르면 돼요. 분산이 가장 큰 방향을 고르는 거예요. 그리고 그 방향은 공분산 행렬의 고유벡터 중 하나로 정확히 떨어집니다.

중심화된 데이터 행렬 $X \in \mathbb{R}^{n \times d}$ 의 공분산행렬을 $\Sigma = \frac{1}{n} X^T X$ 라 하자.
 $\|w\|=1$ 인 w 중 사영분산 $w^T \Sigma w$ 를 최대화하는 것은 Σ 의 최대 고유값에 대응하는 고유벡터이다.

2D 데이터 산점도와 공분산 타원



공분산 타원의 장축은 데이터가 가장 넓게 퍼진 방향, 즉 최대 고유값에 대응하는 고유벡터와 일치한다.

직접 풀어보기

지금 목표는 $w^T \Sigma w$ 를 최대화하는 것이다. 다만 아무 w 나 되는 게 아니라 $\|w\|=1$ 이라는 제약을 지켜야 한다. 목적함수만 놓고 미분해서는 이 제약을 반영할 수 없다. 그래서 제약이 있는 최댓값 문제를 풀 때 쓰는 표준 도구인 라그랑주 승수법을 쓴다. 제약을 어기면 벌점을 주는 새 변수 λ 를 도입해서 목적함수와 제약을 하나의 식으로 합친다. 이렇게 만든 식을 라그랑지안이라 부르고 $L(w, \lambda) = w^T \Sigma w - \lambda(\|w\|^2 - 1)$ 로 쓴다.

주성분분석(PCA)의 최적 방향

왜 그런가

괄호 안에는 제약이 지켜졌는지를 0이 되는 식으로 적어요. 우리 제약은 $\|w\|=1$ 이예요. 이걸 $w^T w - 1 = 0$ 형태로 바꿔서 그대로 넣은 거예요. 이렇게 등호로 정리한 제약식을 등호 제약항이라고 불러요.

정답: $w^T w - 1$

숫자로 보면

추상적인 최적화 논중에 들어가기 전에 공분산행렬 하나를 직접 손에 쥐고 계산해보면 명제가 말하는 바가 훨씬 선명해집니다.

공분산행렬이 다음과 같다고 합시다.

$$\Sigma = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$$

이 행렬의 고유값은 4와 2이고 각각의 고유벡터는 $(1, 1)/\sqrt{2}$ 와 $(1, -1)/\sqrt{2}$ 입니다. 실제로 $\Sigma(1, 1)^T = (4, 4)^T = 4(1, 1)^T$ 이고 $\Sigma(1, -1)^T = (2, -2)^T = 2(1, -1)^T$ 이므로 고유값 방정식이 그대로 성립합니다.

이제 단위벡터 몇 개를 골라 사영분산 $w^T \Sigma w$ 를 직접 재봅니다. $w = (1, 0)$ 이면 $w^T \Sigma w = 3$ 입니다. $w = (1, 1)/\sqrt{2}$ 이면 $w^T \Sigma w = 4$ 입니다. $w = (1, -1)/\sqrt{2}$ 이면 $w^T \Sigma w = 2$ 입니다.

세 값 중 가장 큰 것은 4이고 이때 쓴 방향이 정확히 가장 큰 고유값 4에 대응하는 고유벡터입니다. 반대로 가장 작은 값 2도 가장 작은 고유값에 대응하는 고유벡터에서 나왔습니다. 아래 증명은 이 대응이 우연이 아니라 라그랑주 승수법으로 언제나 성립함을 보입니다.

경사하강법의 하강 보장

경사하강법은 딥러닝 학습에서 가장 기본적인 방법이에요. 매 스텝마다 기울기가 가리키는 반대 방향으로 조금씩 움직여서 손실을 줄여요. 그런데 그 걸음 폭인 학습률이 너무 크면 오히려 손실이 늘어날 수도 있어요. 여기서는 걸음 폭이 충분히 작으면 손실이 실제로 줄어든다는 걸 확인합니다. 도구는 함수를 근사하는 표준 방법인 테일러 근사예요.

∇L 이 립시츠 상수 K 로 립시츠 연속(그래디언트가 갑자기 확 튀지 않고, K 이상의 속도로는 변하지 않는다는 뜻)이면, $\eta < 1/K$ 일 때 $\theta' = \theta - \eta \nabla L(\theta)$ 는 $L(\theta') \leq L(\theta)$ 를 만족한다.

θ_0 (시작점)

최소점

참고: 손실함수 $L(\theta)$ 의 그래프

손실 등고선 위에서 경사하강법이 내리막 방향으로 스텝을 밟아 최소점에 수렴한다.

직접 풀어보기

이제 이 상한식 안의 $\theta' - \theta$ 자리에, 우리가 실제로 쓰는 경사하강법의 갱신식 $\theta' = \theta - \eta \nabla L(\theta)$ 을 대입할 차례다. 이항만 하면 $\theta' - \theta =$ 이다.

경사하강법의 하강 보장

왜 그런가

갱신식을 그대로 옮겨 적으면 나오는 식이에요. 별도의 계산이 필요 없어요.

정답: $-\eta \nabla L(\theta)$

숫자로 보면

증명에 들어가기 전에 간단한 손실함수 하나로 실제 스텝을 밟아보면 부등식이 왜 성립하는지 바로 감이 옵니다.

손실함수를 $L(\theta) = \theta^2$ 로 둡니다. 그래디언트는 $\nabla L(\theta) = 2\theta$ 이고 이 그래디언트는 $K = 2$ 로 립시츠 연속입니다.

학습률 조건 $\eta < 1/K$ 는 $\eta < 0.5$ 를 뜻합니다.

$\theta = 3$ 에서 시작해서 $\eta = 0.2$ 로 한 스텝 밟아봅니다. 그래디언트는 $\nabla L(3) = 6$ 이고 갱신식은 다음과 같습니다.

$$\theta' = 3 - 0.2 \times 6 = 1.8$$

손실값을 비교하면 $L(3) = 9$ 이고 $L(1.8) = 3.24$ 입니다. 실제로 손실이 5.76만큼 줄었습니다.


증명에서 얻는 2차 상한식도 이 숫자와 정확히 맞아떨어집니다. $\frac{K\eta}{2} = 0.2$ 이므로 $1 - \frac{K\eta}{2} = 0.8$ 이고, 상한식이 예측하는 감소량은 $\eta \left(1 - \frac{K\eta}{2}\right) \|\nabla L(3)\|^2 = 0.2 \times 0.8 \times 36 = 5.76$ 입니다. 함수가 정확히 이차식이라 상한식이 등호로 딱 맞습니다.

아래 증명은 이 감소가 이 함수 하나만의 우연이 아니라 립시츠 조건과 작은 학습률만 있으면 항상 성립하는 사실임을 보입니다.

베이즈 정리

평소에 믿던 확률인 사전확률이 있어요. 여기에 새로 관찰한 증거를 더하면 믿음은 어떻게 업데이트될까요. 베이즈 정리는 이 질문에 정확한 공식으로 답해요. 나이브베이즈 분류기부터 베이지안 딥러닝까지 확률적 추론이라는 이름이 붙은 거의 모든 방법의 뿌리가 여기에 있어요.

$$\text{사건 } A, P(B) > 0 \text{에 대해 } P(A|B) = \frac{P(B|A)P(A)}{P(B)}.$$



사전확률 갈래(A/A^c) 뒤에 우도 갈래(양성/음성)가 이어진다. 실선·굵은선(양성)과 점선(음성)으로 흑백에서도 경로가 구분된다.

직접 풀어보기

두 식을 자세히 보면 공통점이 있습니다. 둘 다 $P(A \cap B)$ 를 담고 있습니다. 이것은 두 사건이 동시에 일어날 확률입니다. 이 공통항을 다리 삼아 두 식을 하나로 잇는 것이 다음 목표입니다. 그러려면 먼저 두 번째 식을 $P(A \cap B)$ 하나만 남도록 정리해야 합니다. $P(B|A) = \frac{P(A \cap B)}{P(A)}$ 의 양변에 $P(A)$ 를 곱하면 $P(A \cap B) = \underline{\hspace{1cm}}$ 입니다.

베이즈 정리

왜 그런가

$P(B|A) = P(A \cap B)/P(A)$ 라는 정의식 양변에 $P(A)$ 를 곱하기만 하면 나오는 식입니다. 새로운 계산이 아니라 식의 모양만 바꾼 것입니다.

정답: $P(B|A)P(A)$

숫자로 보면

공식만 봐서는 감이 잘 안 옵니다. 숫자를 직접 넣어봅시다.

사건 A 를 어떤 질병에 걸린 경우, 사건 B 를 검사에서 양성인 경우라 하겠습니다. 이 질병의 유병률은 1%이고 검사의 민감도는 90%입니다. 건강한 사람이 잘못 양성 판정을 받는 위양성률은 5%라 하겠습니다. 숫자로 쓰면 $P(A) = 0.01$, $P(B|A) = 0.9$, $P(B|A^c) = 0.05$ 입니다.

먼저 전확률법칙으로 양성인 나올 전체 확률 $P(B)$ 부터 구합니다.

$$P(B) = 0.9 \times 0.01 + 0.05 \times 0.99 = 0.009 + 0.0495 = 0.0585$$

이제 베이즈 정리를 그대로 적용합니다.

$$P(A|B) = \frac{0.9 \times 0.01}{0.0585} = \frac{0.009}{0.0585} \approx 0.154$$

양성 판정을 받아도 실제로 질병일 확률은 약 15.4%밖에 되지 않습니다. 검사가 꽤 정확해 보여도 유병률 자체가 낮으면 사전확률의 영향이 그만큼 크게 남습니다. 아래 증명은 이 계산이 우연이 아니라 조건부확률의 정의에서 항상 성립하는 공식임을 보입니다.

교차엔트로피와 엔트로피·KL발산의 관계

분류 모델을 학습시킬 때는 거의 항상 교차엔트로피 손실을 씁니다. 그런데 이 손실은 사실 두 조각으로 나뉩니다. 하나는 정답분포 자체가 원래 가진 불확실성인 엔트로피입니다. 다른 하나는 내 예측이 정답과 얼마나 다른지를 재는 KL발산입니다. 이 관계를 알고 나면 교차엔트로피를 줄이는 일이 왜 예측을 정답에 가깝게 만드는지 자연스럽게 이해됩니다.

$$\text{두 분포 } p, q \text{에 대해 } H(p, q) = H(p) + D_{KL}(p||q).$$

직접 풀어보기

이제 KL발산 쪽에서 접근해봅시다. KL발산은 두 분포가 얼마나 다른지 재는 지표입니다. 정의는 $D_{KL}(p||q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$ 입니다. 이 식을 교차엔트로피와 이어붙이려면 로그 안의 나눗셈을 뺄셈으로 풀어야 합니다. 그러면 합을 두 조각으로 갈라놓을 수 있습니다. 로그의 성질 $\log(p/q) = \log p - \log q$ 를 쓰면 $D_{KL}(p||q) = \sum_x p(x) \log p(x) - \sum_x \underline{\hspace{1cm}}$ 입니다.

교차엔트로피와 엔트로피·KL발산의 관계

왜 그런가

$\log(p/q) = \log p - \log q$ 로 나눈 뒤 양쪽에 $p(x)$ 를 곱합니다. 그러면 합이 두 조각으로 자연스럽게 갈라집니다. 뒤에 남은 조각이 정확히 이 빈칸의 답입니다.

정답: $p(x) \log q(x)$

숫자로 보면

교차엔트로피가 엔트로피와 KL발산의 합이라는 명제를 숫자로 먼저 확인해봅시다. 로그는 밑을 2로 사용합니다.

정답분포가 $p = (0.5, 0.5)$ 인 이진분류 문제를 생각합니다. 모델이 내놓은 예측분포는 $q = (0.9, 0.1)$ 로 한쪽에 치우쳐 있습니다.

$$H(p) = -0.5 \log_2 0.5 - 0.5 \log_2 0.5 = 1$$

정답분포 자체의 엔트로피는 1비트입니다. 이제 교차엔트로피를 계산합니다.

$$H(p, q) = -0.5 \log_2 0.9 - 0.5 \log_2 0.1 \approx 0.076 + 1.661 = 1.737$$

같은 분포로 KL발산도 구해봅시다.

$$D_{KL}(p||q) = 0.5 \log_2 \frac{0.5}{0.9} + 0.5 \log_2 \frac{0.5}{0.1} \approx -0.424 + 1.161 = 0.737$$


두 값을 더하면 $H(p) + D_{KL}(p||q) = 1 + 0.737 = 1.737$ 이고 이는 방금 구한 교차엔트로피 $H(p, q)$ 와 정확히 같습니다. 아래 증명은 이 등식이 이 숫자쌍에서만 우연히 맞아떨어진 것이 아니라 임의의 p, q 에서 항상 성립하는 사실임을 보입니다.

의사결정나무 재귀 분기의 정지성

의사결정나무는 뿌리 노드에서 시작해서 데이터를 계속 둘로 쪼개며 자란다. 그런데 이 재귀적 분기가 정말 유한 번 만에 멈춘다는 보장이 있을까. 데이터가 유한하다면 답은 그렇다. 각 분기가 데이터를 진짜로 쪼개는 한, 나무는 반드시 유한한 횟수 안에서 멈춘다는 것을 확인한다.

유한한 n 개의 데이터로 시작한 의사결정나무에서, 매 분기가 노드의 데이터를 두 개의 비어있지 않은 부분집합으로 나눈다면, 전체 재귀적 분기 과정은 최대 $n - 1$ 번의 분기 안에 멈춘다.

대두리만 = 아직 분기 가능



재귀된 원 = 더 쪼개지는 일(크기 1)

분기 3번($=n-1$) 안에 앞 4개가 전부 데이터 1개짜리로 멈춘다.

직접 풀어보기

분기가 한 번 일어날 때마다 나무의 구조에 무슨 일이 일어나는지 살펴본다. 앞 노드 하나를 골라 그 데이터를 둘로 쪼개면, 그 앞은 더 이상 앞이 아니게 되고 대신 새로운 앞 두 개가 생긴다. 앞 하나가 사라지고 앞 두 개가 새로 생기므로 앞의 총 개수는 정확히 하나만큼 늘어난다.

그러니 분기를 k 번 반복한 뒤의 앞 개수는 _____ 이다.

의사결정나무 재귀 분기의 정지성

왜 그런가

시작할 때 앞은 1개이고 분기 한 번마다 앞이 정확히 1개씩 늘어난다. k 번 반복했으니 처음의 1에 k 를 더한 값이 남는다.

정답: $1 + k$

숫자로 보면

추상적인 부등식을 보기 전에 데이터 4개짜리 아주 작은 나무를 직접 쪼개보면 왜 분기 횟수가 딱 $n - 1$ 번에서 막히는지 눈으로 확인할 수 있다.

데이터 4개로 시작한 뿌리 노드가 있다. 앞이 하나뿐이니 $L = 1$ 이다.

첫 분기. 4개를 3개와 1개로 나눈다. 앞이 2개가 되었으니 $k = 1$ 에서 $1 + k = 2$ 가 정확히 맞아떨어진다.

둘째, 셋째 분기. 3개짜리 앞을 2개와 1개로 쪼개면 앞은 3개가 되고($k = 2, 1 + k = 3$), 남은 2개짜리 앞을 1개와 1개로 쪼개면 앞은 4개가 된다($k = 3, 1 + k = 4$).

이제 모든 앞에 데이터가 정확히 1개씩만 남았다. 분기란 정의상 데이터를 두 개의 비어있지 않은 부분집합으로 나누는 것인데 데이터가 1개뿐인 앞은 더 쪼갤 방법이 없다.

$$k_{\max} = 3 = n - 1 = 4 - 1$$

분기는 정확히 3번에서 멈췄고 이는 $n - 1$ 과 같다. 아래 증명은 이 한계가 데이터 4개짜리 특수한 경우가 아니라 임의의 n 에서 항상 성립하는 사실임을 보인다.

조건수와 선형시스템의 오차 민감도

컴퓨터로 계산할 땐 아주 작은 반올림 오차가 늘 섞여요. 진짜 문제는 오차가 섞이는지 여부가 아니에요. 그 작은 오차가 계산 과정에서 얼마나 크게 부풀려지는지가 진짜 문제예요. 그 부풀림 정도를 미리 알려주는 지표가 조건수예요. 수치해석에서는 조건수가 큰 상태를 ill-conditioned라고 불러요. 이런 경우엔 선형회귀에서 $(X^T X)^{-1}$ 을 구하는 것처럼 이론적으로는 맞는 계산도 수치적으로 불안정해질 수 있어요.

$$Ax = b \text{에서 } b \text{에 오차 } \delta b \text{가 생기면 } \frac{\|\delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\delta b\|}{\|b\|}, \kappa(A) = \|A\| \|A^{-1}\|.$$

단위원 (오차 δb) $\kappa(A)=100$ 배 증폭된 타원 $\alpha_1=1$ A
 $\alpha_2=1$

장축 60 (x10 증폭)

단축 극도로 짧음 ($\alpha_2 \approx 0.01$)

$$\|b(x)\|/|x| \leq \kappa(A) \cdot \|b(b)\|/|b| = 100 \times \text{상대오차}$$

단위원이 A 를 거치며 극도로 납작한 타원이 되면 오차가 특이값 비율 $\kappa(A)$ 만큼 증폭된다.

직접 풀어보기

둘 사이의 관계를 보려면 원래 식을 빼서 순수하게 오차끼리의 관계만 남기는 게 자연스러운 다음 수입니다. $A(x + \delta x) = b + \delta b$ 에서 원래 식 $Ax = b$ 를 빼면 $A\delta x = \delta b$ 가 남습니다. 여기서 양변에 A^{-1} 을 곱하면 $\delta x = \underline{\hspace{1cm}}$ 입니다.

조건수와 선형시스템의 오차 민감도

왜 그런가

$A\delta x = \delta b$ 의 양쪽에 A^{-1} 를 곱하면 왼쪽은 δx 만 남고 오른쪽은 $A^{-1}\delta b$ 가 됩니다. 이 식은 입력의 오차 δb 가 A^{-1} 이라는 변환을 통과하면서 그대로 해의 오차 δx 로 바뀐다는 뜻입니다.

정답: $A^{-1}\delta b$

숫자로 보면

추상적인 부등식에 들어가기 전에 작은 대각행렬 하나로 직접 계산해보면 조건수가 무엇을 재는 값인지 바로 감이 잡힙니다.

$A = \begin{pmatrix} 1 & 0 \\ 0 & 0.01 \end{pmatrix}$ 를 씁니다. 대각행렬이라 특이값은 대각성분의 절댓값 그대로 1과 0.01입니다. 그러니 조건수는 $\kappa(A) = \|A\| \|A^{-1}\| = \frac{1}{0.01} = 100$ 입니다.

$$Ax = b, \quad x = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 0.01 \end{pmatrix}$$

이제 b 의 둘째 성분에만 작은 오차 $\delta b = \begin{pmatrix} 0 \\ 0.0001 \end{pmatrix}$ 를 더해봅시다. 입력의 상대오차는 $\|\delta b\|/\|b\| \approx 0.0001/1.00005 \approx 0.0001$ 로 아주 작습니다.

$A^{-1} = \begin{pmatrix} 1 & 0 \\ 0 & 100 \end{pmatrix}$ 이므로 $\delta x = A^{-1}\delta b = \begin{pmatrix} 0 \\ 0.01 \end{pmatrix}$ 입니다. x 의 상대오차는 $\|\delta x\|/\|x\| \approx 0.01/1.41421 \approx 0.00707$ 입니다.

입력의 상대오차는 0.0001인데 해의 상대오차는 0.00707로 약 70배나 커졌습니다. 70은 정확히 조건수 $\kappa(A) = 100$ 이 정해둔 상한 아래에 들어갑니다.

아래 증명은 이 증폭 배율이 이 특정한 행렬에서만 생기는 우연이 아니라 임의의 A 와 임의의 오차에서 조건수로 정확히 상한이 잡히는 사실임을 보입니다.